

修 士 論 文

Master Thesis

CNN-Transformer ハイブリッドアーキテクチャに
基づく虚血性脳卒中 CT/CTP 画像セグメンテーション
モデルの改善

Improved Ischemic Stroke CT/CTP Image
Segmentation Models Based on CNN-Transformer
Hybrid Architecture

名古屋市立大学大学院理学研究科
Graduate School of Science, Nagoya City University

2025 年 1 月 22 日

学籍番号 237715 BA YONGHAO

指導教員 渡邊裕司

目次

要旨	1
第一章 序論	2
1.1. 研究背景	2
1.2. 関連研究	3
1.3. 研究目的	6
第二章 従来手法	8
2.1. CNN と LeNet	8
2.1.1. CNN の構成	8
2.1.2. LeNet	10
2.2. AlexNet	11
2.3. VGGNet	12
2.4. Fully Convolutional Network	14
2.5. U-Net	16
2.6. Transformer	17
2.7. Vision Transformer	19
2.8. TransUNet	20
2.9. Swin Transformer	21
2.10. 先行モデル : DeepTransUNet	23
第三章 提案手法	26
3.1. swinTUNet	26
3.2. swinTWUNet	27
3.3. swinTXUNet	29
3.4. swinTAUNet	31
第四章 実験	35
4.1. データセット	35
4.2. 前処理	36
4.3. 損失関数と評価指標	37
4.3.1. Dice 係数	37
4.3.2. Soft Dice Loss	37
4.4. 実験	38
4.4.1. 実験環境	38
4.4.2. 実験結果	38
4.4.3. アブレーション実験	45

第五章 考察	47
謝辭	49
参考文献	50

要旨

Image segmentation is crucial for many applications, but achieving high performance in complex real-world scenarios remains challenging. In this study, we explore combining CNNs and Transformers for feature extraction and propose new models for the publicly available ischemic stroke CT/CTP image dataset ISLES2018. We base our models on the traditional TransUNet and significantly enhance its encoder. Experiments show that our proposed method achieves a validation accuracy of 76%, about 15% higher than the previous model, without relying on pre-training. Test results confirm the effectiveness of our method and demonstrate the potential of CNN-Transformer hybrid models for feature extraction.

虚血性脳卒中は脳梗塞ともいわれ、脳血管の閉塞に伴い脳機能不全を引き起こす疾患である。頭部 CT や CTP 検査の結果は、この疾患の診断に極めて重要である。CT や CTP の長所として、短時間の撮像が可能であり、呼吸や血圧を維持する治療を行いながらも検査できる。しかし、撮影された画像から脳卒中の病巣を手作業で判定するのは時間と労力を要し、主観的な影響が出やすい。そのため、人工知能の画像認識技術を用いて、迅速かつ正確に医用画像を自動分割するセグメンテーションモデルが様々提案され、医師の診断を支援する。近年では、深層学習の Transformer に基づいたモデルが医用画像セグメンテーションによく使われるが、既存モデルの TransUNet では小規模脳卒中データセットに対しては精度が低かった。

我々の先行研究では、この問題を解決するため、TransUNet を元に、エンコーダ部分を Xception モジュールに置き換えた新しいモデル DeepTransUNet を提案した。セグメンテーション精度が 61%に向上したものの、満足のいく性能を示しておらず、小さな病巣に対して感度が低いという問題が残っていた。

そこで本研究では、特徴抽出のために畳み込みニューラルネットワーク (Convolutional Neural Network、以下 CNN) と Transformer を組み合わせた新しいハイブリッドモデルを提案する。そして、公開されている虚血性脳卒中 CT/CTP データセット ISLES2018 (ISCHEMIC STROKE LESION SEGMENTATION) を用いて実験を行い、提案モデルの有効性を検証する。AdamW を Optimizer とし、ReduceLROnPlateau を Scheduler として使い、モデル訓練には Dice 係数に基づいて Soft Dice Loss を損失関数として使用し、Dice 係数で評価をする。

実験結果として、提案した新しいモデルが従来モデルより大幅に精度が向上して 76%を達成した。収束速度は従来モデルより遅いものの、安定した学習効果を示した。また、出力結果から、提案モデルでは判定した病巣の大きさと形状において大きな改善が見られ、極端な状況でもセグメンテーション効果を維持していた。本研究は、医用画像セグメンテーションモデルに新しい構造をもたらし、CNN と Transformer を組み合わせたハイブリッドアーキテクチャの有効性とポテンシャルを示せたといえる。

第一章 序論

1. 1. 研究背景

虚血性脳卒中は、脳血管の狭窄や閉塞により脳組織に血流不足が生じ、酸素や栄養が十分に供給されなくなることが主因で発症する[1]。脳卒中は脳血管障害の一つであり、心血管系疾患と並んで全世界において主要な死因の一つでもあり、虚血性脳卒中の発症率および死亡率は依然として高いレベルにある。WHO の「グローバル健康推定—特定死因 2000-2019」[2]によると、2000 年には脳卒中による死亡者数が約 546 万人に達し、そのうち虚血性脳卒中での死亡数が約 247 万人であった。さらに、2020 年から 2030 年にかけての虚血性脳卒中の予測動向の研究[3]によると、世界の年齢標準化虚血性脳卒中罹患率は、2030 年までに人口 10 万人当たり 89.32 人に上昇すると予測されている (EAPC=0.89)。そして、虚血性脳卒中発症率は 2020 年から 2030 年の間に、男女とも、すべての年齢層で、すべての社会人口統計学的指標 (SDI) の五分位で増加すると述べている。2021 年の厚生労働省の人口動態統計[4]によると、2021 年には日本における虚血性脳卒中の死者は約 58 万人で、死亡率は 47.6%であった。脳卒中は日本人の死因の第 4 位、寝たきりとなる原因の第 1 位の病気である。脳卒中は、介護が必要となる主な要因であるなど、私たちの生活に大きな影響を及ぼす病気である[5]。

脳卒中の原因となる脳血管障害は、動脈硬化、血栓形成、動脈瘤などのリスクファクターによって悪化し、脳への血流遮断が生じた場合に虚血性脳卒中を発症することが多い。この疾患は、脳の局所的な血流不足により、細胞レベルでの代謝変化を引き起こす。具体的には、脳への血流が一定のレベルまで低下すると、アデノシン三リン酸 ATP の供給不足やグルコース代謝の停止が生じ、細胞死の経路が活性化される。この状態を「ペナンプラ」[6]と呼び、治療によって回復可能な領域を指す。MSD マニュアル[7]において、灌流量が正常の 5%を下回る状態が 5 分以上持続すると、一部のニューロンに細胞死が生じるが、脳損傷の程度は虚血の重症度に依存する。軽度であれば損傷は緩徐に進行するため、たとえ灌流量が正常の 40%であっても、脳組織が完全に死滅するまでには 3~6 時間かかる可能性がある。しかしながら、重度の虚血が 15~30 分以上続けば、病巣の全ての組織が壊死に陥る。このように、虚血性脳卒中は発症からの経過時間が重要な要素であり、早期の診断と治療が患者の生存率や QOL (Quality of Life) に大きな影響を与える。

早期診断および治療法の開発が重要視される中で、CT (Computed Tomography) や MRI (Magnetic Resonance Imaging) を用いた医用画像技術[8]がポイントとなる。CT 検査は短時間で脳内出血を明確に捉えることができるため、急性期脳卒中の診断において広く利用されている[9]。また、呼吸や血圧を維持する治療を行いながらも検査できる。ただし、CT は血管の状態を詳細に確認することが難しいため、近年では造影剤を用いた CT 灌流成像 (CTP) が用いられることが増えている。造影剤によって脳血流動態を可視化し、灌流パ

ラメーターを抽出することで、病巣を的確に把握することが可能となる[10]。一方、MRI は CT より測定に時間を要するものの、病巣の検出精度が高く、さらに拡散強調画像 (Diffusion-Weighted Image: DWI) を用いることで急性期の小さな病巣を明確に捉えられる。

これらの画像診断技術の進展にもかかわらず、脳卒中患者の診療を担う医師の不足や負担が大きな課題となっている。撮影された画像から脳卒中の病巣を手作業で判定するのは時間と労力を要し、主観的な影響が出やすい。日本のデータセット J-ASPECT による研究 [11]では、専任の医師の数が多い病院ほど、30 日間の入院死亡率が低いことが確認されており、専門医の充実が患者の予後改善に直結することが示されている。

そこで、人工知能 (Artificial Intelligence、以下 AI) の画像認識技術を用いて、医用画像を自動分割するセグメンテーション手法が幅広く研究され、医師の診断支援を目指している。AI を活用した診断支援システムの利点は、短時間で高精度な診断が可能であること、再現性が高く拡張性に優れていることにある。これにより、限られたリソースを活用し、患者に対する診療の質を向上させることが可能となる。さらに、脳卒中の予防や早期治療においても、AI を用いた個別化予測モデル[12]の開発が進んでおり、将来的には患者ごとのリスク因子を詳細に解析することで、発症リスクの低減を図ることが期待される。虚血性脳卒中の予防と診断、治療においては技術の進展が不可欠であり、特に AI および深層学習 (AI 技術の中核をなす機械学習の手法) は診断支援に大きな役割を果たすことができ、患者の生存率や QOL の向上が可能となるとともに、医療従事者を含めた社会全体に与える負担の軽減が期待されている。

1. 2. 関連研究

画像認識を含むコンピュータービジョンとは、コンピューターが画像や映像から情報を取得し、それを解析・理解する技術のことを指す。これにより、コンピューターは人間の視覚と同様に、物体認識、シーン理解、動作解析などを行うことができる。コンピュータービジョンの初期研究は主に「畳み込みニューラルネットワーク (Convolutional Neural Network、以下 CNN)」に基づいていた。1998 年に LeCun ら[13]は、手書き数字認識に特化した CNN アーキテクチャである LeNet-5 を提案し、コンピュータービジョンの基盤を築いた。2012 年には Alex Krizhevsky ら[14]が AlexNet を提案し、大規模データセットと深いネットワークアーキテクチャを活用することで、物体認識の分野を大きく前進させた。AlexNet は過学習 (学習データに過剰に適合した結果、未知のデータに対して予測精度が低下する現象) を防ぐための「Dropout 技術」を導入し、これは現在でも広く使用されている。AlexNet 以前、計算資源とデータセットの制約により、大規模なニューラルネットワークの訓練が困難であり、主流の深層学習はラベルなしのデータから特徴を抽出する「教師なし学習」に焦点を当てていた。しかし、AlexNet の登場により、大規模なラベル付きデータセットを用いた「教師あり学習」へのシフトが起こり、ニューラルネットワー

クがより豊富な特徴を学習できるようになった。

多層ニューラルネットワークを用いた機械学習である深層学習は、画像分類、病巣検出、セマンティックセグメンテーション（画像の各ピクセル（画素）に対してラベルを割り当てる領域分類）などの分野で顕著な成果を上げている。しかし、深層学習モデルの訓練には大量のデータが必要であり、特に大規模なモデルの過学習を防ぐためにより多くのデータを必要とする。医用画像分野では、プライバシーの懸念やデータ取得の困難さから、十分なデータセットを得ることが難しい。そのため、限られたデータを効果的に活用し、特徴を可能な限り多く抽出することが重要となる。また、セグメンテーションタスクでは各ピクセルを分類する必要がある、一般的な分類タスクよりも複雑であり、医用画像セグメンテーションに適した特別な手法が必要である。

現在、医用画像セグメンテーション分野の多くの手法は、VGGNet[15]の特徴抽出、Fully Convolutional Network（以下 FCN）[16]の「skip-connection 構造」と分類方法、UNet[17]の「エンコーダ・デコーダ構造」を取り入れている。まず、2014 年にオックスフォード大学の Visual Geometry Group が提案した VGGNet[15]は、小さな 3×3 の畳み込みカーネルを使用し、パラメーター数を削減しながらネットワークを深くする方法を提案した。これにより、計算量が指数関数的に増加することなく、ネットワークの層の深さを着実に増加させることが可能となった。

次に、2015 年に Jonathan Long ら[16]が提案した FCN は、セマンティックセグメンテーションに深層学習を適用したモデルである。FCN は VGGNet をバックボーンとして利用し、分類タスクの全結合層を畳み込み層に置き換え、出力を一次元から二次元にして、ソフトマックス関数（ニューラルネットワークで使われる活性化関数の一つ）を通じてセグメンテーション結果を得る。これにより、セマンティックセグメンテーションモデルのエンドツーエンドの訓練（深層学習において入力層から出力層までの全層を一貫して学習すること）が可能となり、画像セグメンテーションの先駆けとなった。また、FCN は「skip-connection 構造」を導入し、ダウンサンプリング（画像の解像度を下げる処理）時に失われる情報を回復することで、セグメンテーション精度を向上させた。初期の深層学習ベースの画像セグメンテーション手法は、FCN を中心に展開し、畳み込みのダウンサンプリングで失われた情報をどのように効果的に回復するかに焦点を当てていた。

その後、UNet を中心としたエンコーダ・デコーダの対称的な U 字型構造が使われるようになった。2015 年に提案された UNet[17]は、医用画像分野で最も著名なネットワークアーキテクチャの一つであり、「エンコーダ・デコーダ構造」を導入し、デコーダのアップサンプリング時に skip-connection を利用して損失した情報を回復した。UNet は IEEE 国際生体医工学画像シンポジウム（International Symposium on Biomedical Imaging: ISBI）で優れた結果を達成し、その後の医用画像セグメンテーション分野での研究に深く影響を与えた。Dense Nested Skip Pathways を使った UNet++[18]、Full-scale Skip Connections を使った UNet3+[19]、Residual U-block 構造を提案した U²-Net[20]などの後続の手法は、この構造を

さらに改良し、UNet のアップサンプリング時の情報回復の不完全さをある程度解消した。

その後、セマンティックセグメンテーションの分野では、より高度なアーキテクチャが提案された。特に、DeepLab シリーズは重要な進展を遂げた。DeepLab は、CNN に空洞畳み込み（ダイレーション畳み込み）を提案し、受容野を拡大することで、より広範なコンテキスト情報を捉えることを可能にした。2015 年に提案された DeepLab モデル[21]は、空洞畳み込みと条件付きランダムフィールド（Conditional Random Fields: CRF）を組み合わせ、セグメンテーションの精度を向上させた。2016 年の DeepLab v2[22]では、空洞空間ピラミッドプーリング（Atrous Spatial Pyramid Pooling: ASPP）を導入し、マルチスケールの情報を効果的にキャプチャした。2017 年の DeepLab v3[23]では、ASPP 構造をさらに改良し、より広い範囲の空洞率を使用して性能を向上させた。2018 年の DeepLabv3+[24]では、エンコーダ・デコーダ構造を採用し、詳細な空間情報を回復することで、セグメンテーションの精度と解像度を大幅に向上させた。

しかし、既存の CNN ベースのモデルは、畳み込みカーネルを用いているため、基本的な性質による制限を持っている。CNN は低層特徴の抽出に優れ、パッチレベルでのキーポイント、線、およびいくつかの基本的な画像構造を構成する特徴に得意である。これらの特徴は明確な幾何学的特性を持ち、平行移動や回転などの変換に対して頑健であるが、畳み込みカーネルの受容野の制限により、CNN は画像内のグローバルなコンテキストや長距離の依存関係を捉える能力が制限される。この制限は、全体的な情報の理解が重要となる医用画像セグメンテーション分野において課題となる。さらに、医用画像の複雑さと多様性により、医用画像セグメンテーションの研究は依然として大きな挑戦になっている。例えば、虚血性脳卒中の画像ではコントラストが低く、ぼやけやノイズがあり、セグメンテーション精度に影響を及ぼす。また、異なる医療測定機器（モダリティ）の画像は大きく異なり、標準的な手法では効果的に区別できない。

2017 年に提案された Transformer[25]アーキテクチャは、特徴抽出に新たなパラダイムをもたらした。当初は自然言語処理に適用されていた（代表例は ChatGPT（Chat Generative Pre-trained Transformer））が、2020 年に提案された Vision Transformer（以下 ViT）[26]は、このアーキテクチャを画像分野に適用することに成功した。「注意機構（Attention Mechanism）」を活用することで、Transformer は入力要素間の関係をすべて計算し、長距離の依存関係を直接捉えることができるようになった。これにより、入力から全体的な特徴を抽出することが可能となった。

2021 年には ViT に基づいて、TransUNet[27]が提案され、UNet アーキテクチャに複数の Transformer 層を組み込むことで、特徴抽出能力を強化した。同年、Swin Transformer[28]が提案され、シフトウィンドウを使用した階層的な Transformer 構造を提案し、パッチ間の情報のやり取りができ、画像の全体的な特徴を抽出する能力を向上させた。2022 年に提案された Swin-Unet[29]は、UNet アーキテクチャにおいて CNN を完全に Transformer に置き換えたが、純粋な Transformer を使用した結果は不安定であることが判明した。しかし、

TransUNet などは、大規模データセットに基づいて訓練したものであり、小規模脳卒中データセットに対しては精度が低かった。

そこで我々の先行研究[30]では、この問題を解決するため、TransUNet にアイデアを得て、エンコーダ部分を Xception モジュールに置き換え、TransDeepLab[31]に基づいた DeepTransUNet を提案した。公開されている小規模な虚血性脳卒中 CT/CTP データセット ISLES2018[32] (ISCHEMIC STROKE LESION SEGMENTATION) に対して実験を行い、TransDeepLab の 13.41%と TransUNet の 59.89%のバリデーション精度に対して、DeepTransUNet は 61.86%となり、既存モデルより精度が少し向上した。しかし、これらの手法は脳卒中データセットで満足のいく性能を示しておらず、セグメンテーション精度が低く、小さな病巣に対して感度が低いという問題が残っている。

1.3. 研究目的

本研究は、新たな深層学習に基づく医用画像セグメンテーション手法を提案し、病巣の検出能力を向上させることで、虚血性脳卒中画像の自動セグメンテーション精度を向上させることを目的とする。虚血性脳卒中を迅速かつ正確に診断する方法は、患者の生存期間と生活の質の向上にとって極めて重要である。医用画像は早期診断において重要な役割を果たし、既存の CT や MRI などの画像診断技術と深層学習モデルを組み合わせた自動セグメンテーションは、画像認識と病巣検出の進歩をある程度促進してきた。しかし、医用画像セグメンテーションの分野は、低コントラスト、ノイズ干渉、病変の形態と大きさの多様性、異なるモダリティによる画像間の差異など、多くの課題に直面している。既存モデルの性能を向上させるために、本研究では、より精度が高い自動セグメンテーションを実現するための新しい深層学習モデル構造を設計・実装し、脳卒中画像のセグメンテーション精度の向上を目指す。

既存の研究は主に CNN やその変種である全畳み込みネットワーク FCN、そして UNet などの手法に基づき、医用画像セグメンテーション分野で良好な成果を上げてきた。しかし、畳み込みカーネルの限界により、CNN は全体的な特徴抽出においてボトルネックに直面している。近年提案された Transformer アーキテクチャは全体的な特徴の計算や長期依存関係の処理能力で大きなポテンシャルを示し、医用画像の分野にも利用されている。本研究は、Transformer アーキテクチャと既存の深層学習ネットワークを組み合わせる新しいモデルアーキテクチャを設計し、病巣のセグメンテーション能力を強化し、医用画像セグメンテーションの全体的な精度と安定性を向上させることを目的とする。

具体的には、従来手法を検討した上で、CNN と Transformer を使用し、それぞれの利点を組み合わせて新しいハイブリッドモデルを構築し、脳卒中の CT/CTP 病巣識別に適用する。モデルの入力には CT/CTP 画像を使い、モデルは自動的にそれらの画像の特徴を抽出し、活性化関数の一つであるシグモイド関数を通じてセグメンテーション結果を出力する。

図 1 に示すように公開データセット ISLES2018[32]の各入力には CT と 4 種類の CTP 画像（CBV、CBF、Tmax、MTT）が含まれ、専門家がマークした正解ラベル Mask と比較し、ソフトダイス損失を用いて誤差逆伝播を行い、その誤差を減らすように学習させる。最後に、同じデータセットで従来手法と比較し、提案手法の有効性を検証する。




図 1：虚血性脳卒中 CT/CTP データセット ISLES2018[32]における各モダリティの撮影画像と専門家による正解ラベル Mask の例

第二章 従来手法

本章では、1.2.節で概説した従来手法ならびに我々の先行研究について詳しく説明する。

2.1. CNN と LeNet

2.1.1. CNN の構成

畳み込みニューラルネット (Convolutional Neural Network: CNN) は、従来のニューラルネットワークの深層学習モデルをベースにしており、コンピュータービジョン分野でよく使われている。CNN は、一般的に畳み込み層 (Convolutional layer)、活性化関数層 (Activation function layer)、プーリング層 (Pooling layer)、全結合層 (Full-connection layer) の四つの主要層から構成される。以下では各層について詳しく説明する。

まず、入力データが CNN に渡されると、最初に畳み込み層が処理を行う。この層は、指定されたサイズのスライディングウィンドウを使用して対象データ (行列) を走査する。スライディングウィンドウ内の行列は畳み込みカーネルと呼ばれ、その初期値を設計者が指定するかランダムに生成し、その後特徴量に応じて自動的に調整される。畳み込みカーネルはスライディングウィンドウ内の行列との行列内積演算を行い、スライディングウィンドウが行列全体を走査した後に縮小された行列を得る。

2次元画像に対して畳み込みを行うには、画像 Image を I 、畳み込みカーネル Kernal を K と略すと、対象画像の最初の (i, j) 画素の畳み込み値 $h(i, j)$ は

$$h(i, j) = (I * K)(i, j) = \sum_m \sum_n I(m, n) K(i - m, j - n) \quad (1)$$

となる[33]。例えば図2に示すような 4×4 の画像 (左側の行列) に対して、式(1)に従い 3×3 のカーネル (真ん中の行列) の畳み込み演算により、 2×2 の特徴マップ (右側の行列) を得ることができる。この計算により、画像から特徴抽出ことができるようになる。




図2: 畳み込み計算の流れ

次に、畳み込み層で得られた特徴マップは活性化関数層に渡される。この層の目的は、非線形問題を解くために、ニューロン（ニューラルネットワークを構成する素子）上の特徴から選択的に有効な特徴を増大させ、無効な特徴を減衰させることである。2011 年以前のニューラルネットワークで広く使われていた活性化関数がシグモイド関数であったのに対して、CNN で使われる活性化関数は一般に ReLU（Rectified Linear Unit）関数である。ReLU 関数は以下のように定義され、入力 x が負ならば 0、入力が正ならば x をそのまま出力する。

$$f(x) = \max(0, x) \quad (2)$$

その後、プーリング層が適用される。この層は、データ量とパラメーターを圧縮し、過学習を抑えるために使用される。入力が画像の場合、プーリング層の主な目的は、画像をさらに圧縮することである。画像には多くの情報や特徴が含まれるが、中には画像識別であまり使われない情報や重複している情報もあるため、プーリング層ではこの冗長な情報を取り除き、最も重要な特徴のみを抽出する。最も一般的なプーリング手法はマックスプーリングであり、以下のように計算される。

$$z(i, j) = \max_{(m, n) \in R} y(i + m, j + n) \quad (3)$$

ここで R はプーリングウィンドウの範囲を表す。範囲 R での最大値を求めるこの処理により重要な特徴のみが保持される。

さらに、複数の畳み込み層とプーリング層を組み合わせ、階層的により高次の特徴を抽出する。その後、全結合層に移行する。この層では、得られた特徴マップを 1 次元ベクトルに変換し、分類や回帰などのタスクに対応する出力を生成する。全結合層のニューロン k の出力 o_k は次の数式で表される。

$$o_k = \sum_{i=1}^I v_{k,i} \cdot a_i + c_k \quad (4)$$

ここで a_i は前層のニューロン i の入力、 $v_{k,i}$ はニューロン i とニューロン k の間の重み、 c_k はバイアスを示す。

最後に、ソフトマックス関数（Softmax function）を用いて、分類タスクでは分類すべきラベルの確率分布を出力する。この関数は以下のように定義される。

$$p_k = \frac{\exp(o_k)}{\sum_{j=1}^K \exp(o_j)} \quad (5)$$

ここで o_k は全結合層のニューロン（ここではラベルに相当） k の出力、 K は出力ラベルの総数を示す。この計算により、各ラベルに属する確率が得られる。

2.1.2. LeNet

LeNet[13]は、1998年に Yann LeCun によって開発された CNN であり、手書き数字の認識において重要な役割を果たした。有名な TensorFlow の入門学習データセット MNIST[34]は、その時に作られた。図 3 にそのデータセットを示す。



図 3 : MNIST データセット[34]

LeNet モデルの構成は、図 4 に示すように入力層から出力層まで合計七つの層で構成されている。まず、入力層では 32×32 ピクセルのグレースケール画像が与えられる。この入力サイズは、数字の特徴を詳細に捉えるためである。最初の畳み込み層である C1 層では、六つの 5×5 フィルタを使用して、6 層の 28×28 のニューロンからなる特徴マップを生成する。この層の役割は、エッジや線などの基本的な視覚的特徴を抽出することにある。続くサブサンプリング層の S2 層では、平均プーリングを行い、空間的な次元を 14×14 の半分に削減する。これにより、モデルは位置の変化や歪みに対してロバストになる。次の畳み込み層 C3 では、16 個のフィルタを使用してより複雑な特徴を学習する。この層は前の層からの情報を組み合わせ、高次の特徴を抽出する役割を果たす。続くサブサンプリング層 S4 でも再びプーリングが行われ、データの次元がさらに 5×5 まで削減される。C5 層は完全に接続された畳み込み層であり、120 個のニューロンから構成される。この層は、前の層の全ての特征マップに接続され、高度な特徴を統合する役割を持つ。続く F6 層も完全結合層であり、84 個のニューロンで構成される。ここでは、抽出された特徴を用いて分類の準備が行われる。最後に、出力層では 10 個のニューロンがあり、それぞれが数字のラベル (0 から 9) に対応している。




図 4 : LeNet の構成[13]

従来のニューラルネットワークと比較して、LeNet は畳み込み層とサブサンプリング層を組み合わせたネットワーク構造を提案したことが挙げられる。これにより、画像の空間的構造を保ちながら効果的な特徴抽出が可能となった。また、勾配降下法を用いた誤差逆伝播法による学習を深いネットワークに適用し、効率的なパラメーター更新を実現した。

LeNet は深層学習分野における重要なマイルストーンであり、画像分類タスクに使用された初期の重要なモデルであるため、コンピュータービジョンにおける研究と、その後の深層学習アーキテクチャの開発に多大な影響を与えた。LeNet における畳み込み層とプーリング層の導入、および重み共有の概念は、今日の深層学習モデルにも依然として関連している。

2.2. AlexNet

AlexNet[14]は、Alex Krizhevsky らによって提案された深層学習モデルであり、2012 年の ImageNet Large Scale Visual Recognition Challenge (ILSVRC)[35]において画期的な結果を達成し、多層非線形変換によってより複雑で高レベルの特徴を抽出する能力を実証し、画像分類タスクの精度を劇的に向上させた。

AlexNet は LeNet を基盤として改善し、図 5 に示すように複数の畳み込み層、プーリング層、全結合層を用いる。まず、入力画像は畳み込み層を通じて局所的な特徴が抽出される。続いて、プーリング層が適用され、特徴マップの空間的なサイズを縮小し、計算効率を高めると同時に過学習を防ぐ効果をもたらす。畳み込み層とプーリング層が交互に配置され、層が深くなるにつれてより抽象的な特徴が学習される。活性化関数には ReLU 関数が採用され、これにより勾配消失問題（誤差逆伝播法で学習する際に層が深いニューラルネットワークにおいて勾配がほぼ 0 になって学習が上手くいかなくなる問題）が緩和され、学習の高速化が実現される。また、全結合層では、高次元の特徴を統合して最終的な分類を行う。さらに、Dropout という手法が導入されており、一部のノードをランダムに無効化することで過学習を防ぎ、モデルの汎化性能を向上させている。




図 5 : AlexNet の構成[14]（原画像で図の上部が切れている）

LeNet と比べて、AlexNet は深い層を持つニューラルネットワークを大規模なデータセットで効果的に学習させた点が挙げられる。特に、GPU を活用した高速な計算により、大量のパラメーターを持つモデルの学習が可能となった。また、ReLU 関数や Dropout といった新しい技術の導入により、学習効率とモデルの性能が大幅に向上した。これらの進歩は、深層学習が実用的な問題に適用可能であることを示し、以後の研究開発に大きな影響を与えた。AlexNet はコンピュータービジョンにおける深層学習の有効性を実証し、その後の深層学習の発展の基盤を築いた。また、ILSVRC 2012 の ImageNet での成功は、データのスケールとモデルの深さが性能向上に不可欠であることを示し、大規模データセットの重要性を強調した。これにより、産業界や学术界での深層学習への関心が高まり、多くの応用と研究が活発化した。

2. 3. VGGNet

VGGNet[15]は、2014 年にオックスフォード大学の Visual Geometry Group が提案した CNN で、画像分類タスクで高い性能を発揮するモデルとして知られている。このモデルの特徴はシンプルな構造と効率性であり、多くの応用研究の基盤になっている。

VGGNet の基本的な構成は、図 6 に示すように階層的な畳み込み層、プーリング層、全結合層で成り立っている。入力画像はまず固定サイズ（通常 224×224 ピクセル）にリサイズされ、正規化された後、畳み込み層を通じて特徴マップが抽出される。VGGNet は 3×3 のカーネルを積み重ねることで、より深い層で同等またはそれ以上の受容野（Receptive Field）を得ることができる。例えば、二つの 3×3 カーネルを重ねると、見かけ上の受容野は 5×5 となるが、パラメーター数は大幅に削減される。この設計により、モデルの計算効率が向上し、過学習を抑えつつ性能を向上させることができる。各畳み込み層の後に ReLU 活性化関数が適用される。この活性化関数は非線形性を導入し、ネットワークの表現力を高める役割を果たしている。そして一定の層ごとにプーリング層が配置され、特徴マップの空間的な次元が縮小される。プーリング層は通常 2×2 のカーネルとストライド 2

を使った最大プーリングを採用し、計算効率を高めると同時に過学習を抑制している。この階層的な特徴抽出のプロセスが VGGNet の設計の核心になっている。最終的に特徴マップは全結合層に入力される。VGGNet では通常 3 層の全結合層が使われ、最後の層ではソフトマックス関数を用いて画像の各ラベルに属する確率が出力される。全結合層ではニューロン数が順に 4096、4096、ラベル数（ImageNet の場合は 1000）と設定されていて、ネットワーク全体で学習した特徴が統合されて最終的な分類結果が得られる。




図 6 : VGGNet の構成[15]

VGGNet の設計は「ネットワークの深さが性能を向上させる」という仮説に基づいている。提案されたモデルには 11 層（VGG-11）、13 層（VGG-13）、16 層（VGG-16）、19 層（VGG-19）などのバリエーションがあり（図 7）、従来のモデルよりもはるかに深い層を持つ構造が採用され、この設計がより高次元な特徴を学習可能であることを示した。この「深さ」の重要性は、後に ResNet や DenseNet といったさらに深いモデルの開発につながり、深層学習の進化を促進した。また、VGG の構造はモジュール性の高さも特徴であり、全体的な設計が規則的でシンプルであるため、他のタスクへの転用が容易となった。具体的には、VGG の事前学習済みモデル（Pre-trained Model）は、多くの画像認識タスクや転移学習のベースとして広く使用されるようになった。これにより、計算リソースが限られる環境でも、高い性能を得るための実用的なソリューションを提供することになった。

ConvNet Configuration					
A	A-LRN	B	C	D	E
11 weight layers	11 weight layers	13 weight layers	16 weight layers	16 weight layers	19 weight layers
input (224 × 224 RGB image)					
conv3-64	conv3-64 LRN	conv3-64 conv3-64	conv3-64 conv3-64	conv3-64 conv3-64	conv3-64 conv3-64
maxpool					
conv3-128	conv3-128	conv3-128 conv3-128	conv3-128 conv3-128	conv3-128 conv3-128	conv3-128 conv3-128
maxpool					
conv3-256 conv3-256	conv3-256 conv3-256	conv3-256 conv3-256	conv3-256 conv3-256 conv1-256	conv3-256 conv3-256 conv3-256	conv3-256 conv3-256 conv3-256 conv3-256
maxpool					
conv3-512 conv3-512	conv3-512 conv3-512	conv3-512 conv3-512	conv3-512 conv3-512 conv1-512	conv3-512 conv3-512 conv3-512	conv3-512 conv3-512 conv3-512 conv3-512
maxpool					
conv3-512 conv3-512	conv3-512 conv3-512	conv3-512 conv3-512	conv3-512 conv3-512 conv1-512	conv3-512 conv3-512 conv3-512	conv3-512 conv3-512 conv3-512 conv3-512
maxpool					
FC-4096					
FC-4096					
FC-1000					
soft-max					

図 7 : VGGNet の種類[15]

2.4. Fully Convolutional Network

Fully Convolutional Network (FCN) [16]は、画像セグメンテーションタスクに特化して設計された深層学習モデルであり、その基本的な構造は従来の CNN モデルを改良したものであった。FCN は、入力画像全体に対してピクセル単位で分類を行うことを目的としており、これによりセグメンテーションの精度と効率が大幅に向上した。モデルの構成は、特徴抽出を行う畳み込み層、特徴マップを縮小して効率的な計算を可能にするプーリング層、そして従来の全結合層を畳み込みに置き換えた部分から成り立っていた。この全結合層を畳み込みに置き換える手法は FCN の主要な革新点であり、この変更によってネットワークは可変サイズの入力画像に対応可能となり、出力が一次元から二次元に変更し、ピクセルずつ分類できるようになった。

FCN の構成 (図 8) は、従来の VGGNet を基礎としており、特に VGG-16 などの深層ネットワークの特徴抽出能力を活用している。まず、FCN の入力層および中間層では、通常の CNN と同様に畳み込み層とプーリング層を用いる。これらの層は、入力画像から特徴を抽出し、空間情報を圧縮しながら階層的な特徴マップを生成する役割を果たしている。さらに、プーリング層によって解像度が低下した特徴マップを元の画像サイズに復元する

ために、FCN ではデコンボリューション技術を用いたアップサンプリング（図 8 の右側の三つの層）が導入されている。この操作により、 픽셀単位での出力が可能になり、画像全体のセグメンテーションマスクを生成することができる。また、**Skip-Connection** という技術（図 8 における曲線の矢印）が採用され、異なるレイヤーから得られた特徴を統合して使用することで、セグメンテーション結果の精度をさらに向上させている。具体的には、浅い層から抽出された詳細な空間情報と、深い層から得られる抽象的な情報を組み合わせることで、モデルはより精密かつ正確なセグメンテーション結果を生成することが可能になる。出力層では、最終的な特徴マップに対してソフトマックス関数を適用し、 픽셀ごとのラベル確率を計算する。この出力は、画像の各 픽셀に対してどのラベルが最も適しているかを示すものであり、セグメンテーションマスクとして視覚化することができる。




図 8 : FCN の構成[16]

VGGNet が画像全体を分類するために設計されていたのに対し、FCN は全結合層を取り除くことで、空間的な情報を保持した状態で出力を保つことになった。この改良により、画像セグメンテーションタスクにおいて、入力画像の解像度に応じた 픽셀単位の予測を可能にした。また、アップサンプリングやデコンボリューション技術を用いることで、縮小された特徴マップを元の解像度に復元し、高精度なセグメンテーションマップを生成することができるようになった。FCN は、画像セグメンテーション分野の先駆け、その後の技術発展に多大な影響を与えた。特に、U-Net や DeepLab などの後続モデルにおける基盤技術として、 픽셀単位での予測を可能にする手法が取り入れられた。これにより、画像セグメンテーションの分野が飛躍的に発展し、より高度な応用技術の実現が可能となった。このように、FCN の登場は深層学習による画像処理の枠組みを革新し、現在に至るまでの技術進歩における重要なマイルストーンとなっている。

2.5. U-Net

深層学習を基にした初期の画像セグメンテーション手法は、FCN を中心に展開され、畳み込みカーネルによるダウンサンプリングから失われた情報をどのように回復するかに焦点を当てていた。その後、U-Net を中心とした対称的な U 形のエンコーダ・デコーダ構造が徐々に形成された。U-Net[17]は、2015 年に Olaf らによって提案された深層学習モデルであり、医用画像セグメンテーション分野において画期的な成果をもたらした。

U-Net は、図 9 に示すように主にエンコーダ（図中の左側）、ボトルネック（図中の下部）、デコーダ（図中の右側）の三つの部分から構成されている。エンコーダ部分では、入力画像の特徴を抽出するために複数の畳み込み層とプーリング層が用いられる。この処理により、画像の空間情報が徐々に圧縮され、より深い特徴が抽出される。一方、ボトルネック部分はネットワークの中間部分に位置し、エンコーダで圧縮された情報をさらに高次元の特徴空間に変換する。この部分はモデルの性能向上に寄与するため、畳み込み層や正則化手法が採用される。そして、デコーダ部分では、エンコーダで失われた空間情報を復元しながら、特徴を元の画像サイズに再構築する。デコーダにはアップサンプリングや転置畳み込み層が用いられ、エンコーダからの Skip-Connection により対応する層の特徴が結合される。Skip-Connection（同図中央の灰色の矢印）は U-Net の重要な構造であり、低レベルの詳細情報と高レベルの抽象情報を統合する役割を果たす。




図 9 : UNet の構成[17]

U-Net が FCN より大きく改善された点の一つは、その対称的な構造である。エンコーダとデコーダの層数や特徴量の構成が一致しており、効率的な情報伝達と学習を可能にして

いる。この設計により、モデルは小さなデータセットでも高い性能を発揮することができ、医用画像解析などのデータ制約が厳しい分野で特に有用である。

U-Net は、医用画像処理を含むセグメンテーションタスク全般における精度と効率性を大幅に向上させた。U-Net の登場により、小規模なデータセットに基づく高精度なセグメンテーションが可能となり、特に医療現場での応用範囲が広がった。また、そのシンプルで効果的な構造は、他のセグメンテーションモデルの設計における基礎としても機能している。

2.6. Transformer

Transformer[25]は、自然言語処理分野において革新的なモデルとして 2017 年に Ashish Vaswani らによって提案されたアーキテクチャであり、ポイントは自己注意機構（Self-Attention Mechanism）である。従来のリカレントニューラルネットワーク（Recurrent Neural Network: RNN）や長・短期記憶（Long Short Term Memory: LSTM）が系列データを扱う際に逐次的な計算に依存していたのに対し、Transformer は並列計算が可能であり、大規模データ処理の効率を飛躍的に向上させた。

図 10 に示す Transformer の主要な構成要素は、エンコーダとデコーダの二つの部分に分かれ、エンコーダは入力されたシーケンスを処理し、情報を潜在的な表現に変換する役割を果たす。一方、デコーダはその表現をもとに出力を生成する。エンコーダとデコーダはいずれも複数の同一構造の層で構成されており、各層は自己注意機構とフィードフォワードニューラルネットワークで構成されている。

自己注意機構では、シーケンス内の各単語が他の単語との関連性を動的に学習し、文脈情報を効果的に捉えることを可能にする。この機構を計算するために、クエリ Q、キーK、バリューV と呼ばれる三つのベクトルが入力から生成される（図 11）。それぞれの単語のクエリと他の単語のキーの内積を計算し、関連性スコアを得る。このスコアに基づいてバリューの重み付き和を取り、その結果が自己注意機構の出力となる。また、Multi-Head Attention 構造を用いることで、複数の注意パターンを同時に学習できるようになり、情報の多様な側面を捉える能力が向上する。もう一つの重要な要素は位置エンコーディング（Positional Encoding）である。この機構は、入力シーケンス内の単語の順序情報を保持するために用いられる。Transformer は従来のリカレントニューラルネットワークのようにシーケンシャルな構造を持たないため、位置エンコーディングを加えることで単語の位置関係を明示的にモデルに提供する。

このような設計により、Transformer は自然言語処理分野だけでなく、画像処理分野にも応用されるようになった。従来の CNN に比べ、Transformer は長距離の依存関係を効率的に学習できるという利点を持つ。画像処理においても、各ピクセルや特徴量間の入力に対し全体的な関係性を捉える能力が特に有用である。さらに、CNN のように固定サイズのカ

一ネルで局所的な情報を処理するのではなく、自己注意機構を用いることで、入力データ全体を一度に処理することが可能となる。この特性により、計算の並列化が容易になり、処理速度の向上が図れる。

Transformer の登場は様々な分野での技術的進展に大きく貢献した。BERT (Bidirectional Encoder Representations from Transformers) や GPT (Generative Pre-trained Transformer) などの言語モデルが開発され、自然言語処理分野におけるタスクの性能が飛躍的に向上した。また、この後で詳しく述べる Vision Transformer の提案により、CV 分野でも従来の CNN を超えた結果が示され、従来のモデル設計に対する新たな視点を提供し、自己注意機構の汎用性を証明した。





図 10 : Transformer の構成[25]

Scaled Dot-Product Attention



Multi-Head Attention




図 11 : Self -Attention 構造[25]

2.7. Vision Transformer

2020 年に Alexey Dosovitskiy らによって提案された Vision Transformer（以下 ViT）[26]は、画像認識タスクにおいて Transformer アーキテクチャを適用した画期的なモデルである。ViT は従来の Transformer を基盤としながら、画像データに適応させるための特有のデザインを取り入れている。具体的には、画像をそのまま処理するのではなく、図 12 に示すように固定サイズのパッチに分割し、それぞれのパッチをトークンとして扱う。このパッチのトークン化は、自然言語処理における単語のトークン化に相当する。これにより、画像データを Transformer が処理可能な形式に変換することが可能となる。パッチ化された画像データに対して、各トークンの位置情報をエンコードする位置エンコーディングを加える。これにより、画像内の空間的な位置関係が保持され、自己注意機構が画像全体の特徴を効果的に学習できるようになる。この点は、自然言語処理においても重要な構成要素であり、ViT では画像データに対して応用されている。

ViT では、従来の CNN に依存しない構造を採用したことである。これにより、局所的な特徴だけでなく、入力画像の全体的な特徴を同時に学習する能力が大幅に向上した。従来の CNN では、畳み込み層を通じてピクセルレベルの局所的な特徴を段階的に集約する手法が採られていたが、ViT では自己注意機構を利用して、全トークン間の関係を直接的に捉えるようになった。この改良は、大規模なデータセットを用いた訓練によって特にその強みを発揮し、CNN を上回る性能を示すことが多くなった。

ViT の研究は、深層学習分野における画像処理の方法論に革命をもたらした。このアプローチは、自然言語処理と画像認識という異なるタスクの間に共通する基盤を見出し、Transformer アーキテクチャが汎用的であることを示した。また、この研究により、従来の

手法に比べてより大規模なモデルの構築やトレーニングの可能性が広がり、他の分野への応用が加速した。ViT は、Transformer の適用範囲を拡大するだけでなく、画像認識分野の新たな道を切り開いた。従来の手法の限界を打破し、画像処理における可能性を広げたその貢献は、深層学習の未来をさらに加速させる重要な礎となっている。




図 12 : Vision Transformer の構成[26]

2. 8. TransUNet

2021 年に Jieneng Chen らが提案した TransUNet[27]は、U-Net に基づく医用画像セグメンテーションタスク向けの新しいアーキテクチャであり、Transformer と CNN を融合させたモデルである。従来の U-Net はエンコーダ・デコーダ構造を採用し、局所的な特徴を効率的に捉えることができたが、画像の全体的な特徴を扱うことが苦手であった。一方で、TransUNet はこの問題を解決するため、ViT をエンコーダ部分に統合し、特徴抽出能力を向上させた。

TransUNet は U-Net の基本構造を基盤としており、エンコーダとデコーダから構成される。エンコーダは入力画像から階層的な特徴を抽出し、デコーダは抽出された特徴を元に画像のセグメンテーションマスクを生成する。U-Net の基盤の上に、Transformer の自己注意機構を導入した点が TransUNet の特徴である。TransUNet のエンコーダ部分では、図 13 に示すように従来の U-Net で用いられる CNN のみならず、Transformer を利用して全体的な特徴を取り込む。具体的には、エンコーダで抽出された局所的な特徴マップを変換し、パッチとして Transformer に入力する。これにより、画像全体の特徴を含めて処理することが可能となり、従来の U-Net では困難であった全体的な情報を効果的に利用することがで

きる。デコーダ部分では、Transformer で得られた全体的な特徴を従来の CNN で補完し、ピクセルレベルの再構築を行う。具体的には、エンコーダで得られた特徴マップと Transformer で抽出された全体的な特徴を融合し、それを段階的にアップサンプリングしてセグメンテーションマスクを生成する。この融合によって、局所的な特徴と全体的な特徴のバランスが取れ、従来の U-Net よりも精度の高いセグメンテーションを可能にする。




図 13 : TransUNet の構成[27]

U-Net と比較して、TransUNet は構造を拡張しつつ、Transformer を導入することでセグメンテーションの性能を大幅に向上させた。特に、医用画像分野では、複雑な解剖学的構造を高精度でセグメンテーションする能力が求められるため、TransUNet のようなモデルは大きな利点を持つ。また、計算コストを抑えつつも、全体的な特徴を活用できるという点は、リアルタイムアプリケーションやリソース制限のある環境でも利用可能である。

TransUNet は、Transformer を画像セグメンテーションに応用するという新たな方向性を示し、今後の技術発展に大きな影響を与える可能性を持っている。TransUNet は、U-Net や Transformer という異なるアーキテクチャの長所を組み合わせることで、既存の手法を超えた新しいパラダイムを提供する。このように、TransUNet はセグメンテーションタスクにおける新たな基準を確立し、画像解析における可能性をさらに広げる画期的なモデルである。

2.9. Swin Transformer

Swin Transformer[28]は、ViT の課題を克服しつつ、画像認識や他のビジョンタスクにおける性能をさらに向上させるために設計されたモデルである。

Swin Transformer の特徴的な構造 (図 14) は、スライディングウィンドウベースの自己

注意機構に基づいている。これは、画像全体ではなく、局所的なパッチ内で自己注意を計算する手法であり、計算コストを大幅に削減すると同時に、画像の高解像度情報を効率的に処理可能にする。具体的には、画像を固定サイズのパッチに分割し、それぞれのパッチ内で自己注意機構を適用する。この局所的な注意の仕組みを段階的に拡張することで、階層的に画像全体の文脈を捉える設計が採用されている。さらに Swin Transformer は、図 15 に示すようにシフトウィンドウ（Shifted Window）というデザインを導入し、隣接するウィンドウ間の情報交換を可能にする仕組みであり、局所的な注意だけでは捉えきれない情報を効果的に学習できるように設計されている。この工夫により、従来の ViT で指摘されていた、全体的な構造を捉える能力不足の問題が解消された。




図 14 : Swin Transformer の構成[28]




図 15 : Shift-Window 構造[28]

また、ウィンドウベースの計算手法は、ハードウェアの効率性を最大化する設計ともなっており、特に高解像度画像において ViT を大きく上回る性能を発揮する。もう一つの重要な特徴は、階層的な特徴表現の導入である。Swin Transformer は、図 16 に示すように自然な階層構造を持つ画像データに適した設計を採用しており、浅い層ではローカルな特徴を、深い層ではよりグローバルな特徴を効果的に学習することができる。この階層的な構造は、従来の CNN と Transformer の利点を融合させた設計とも言え、画像分類だけでなく、セグメンテーションや物体検出などの多様なタスクにおいて一貫して優れた性能を示している。




図 16 : Swin Transformer の階層化 [28]

Swin Transformer の ViT に対する最大の改良点は、計算効率とスケーラビリティの向上である。ViT は、大規模なデータセットがなければ十分な性能を発揮できないという課題を抱えていたが、Swin Transformer はその計算効率の高さから、中規模のデータセットでも効果的に学習できる。この改良により、より幅広いアプリケーションへの展開が可能となり、特に高解像度画像処理やリアルタイム処理が求められる分野での利用が進んでいる。

Swin Transformer は深層学習分野において大きな影響を与えたといえる。その革新的なデザインにより、ViT の限界を克服しつつ、CNN と Transformer の利点を統合した新たなアーキテクチャを提供した。この研究は、画像処理におけるモデル設計の新たな方向性を示し、セグメンテーションや検出タスクを含む幅広い分野での応用を可能にした。

2. 10. 先行手法 : DeepTransUNet

我々の先行研究である DeepTransUNet[30]は、Transformer と DeepLab v3Plus を組み合わせた新しい医用画像セグメンテーションモデルを提案し、虚血性脳卒中データセット ISLES2018[32]に適用して精度を評価している。このモデルは、既存の TransUNet[27]や

TransDeepLab[31]における小規模データセットに対して精度が低いという課題を克服し、計算効率を向上させながらも精度を維持または向上させることを目的としている。

図 17 に示す DeepTransUNet の構成は、主に Xception モジュール、ASPP モジュール、そして ViT モジュールを中心に設計されている。エンコーダ部分では Xception モジュールを用いて低レベル特徴を効率的に抽出する。このモジュールは一般的な畳み込みを深さ別に分離可能な畳み込み層に置き換えることで、計算効率を向上させながら特徴抽出の性能を損なわない構造となっている。その後、ASPP モジュールが導入され、異なるスケールの特徴を同時に処理し、マルチスケールの特徴情報を抽出する。最後に、ViT モジュールが画像の長期依存性を学習し、全体的な特徴をモデルに組み込む。デコーダ部分では、Skip Connection を利用してエンコーダで抽出された浅いレベルの特徴をアップサンプリングされた深いレベル特徴と統合する。このデザインにより、空間的な情報の損失を最小限に抑えながら解像度を復元し、入力画像と同じサイズの出力を生成することが可能になる。このようにエンコーダとデコーダの間で情報を効果的にやり取りする設計は、セグメンテーション精度を向上させる。




図 17 : DeepTransUNet の構成[30]

DeepTransUNet の改善点として、Xception モジュール、ASPP モジュール、Vision

Transformer モジュールを組み合わせることで、モデルの性能と計算効率をバランス良く向上させた点が挙げられる。具体的には、Xception モジュールの導入により計算コストが削減され、ASPP モジュールがローカルとグローバルの情報を同時に処理することでセグメンテーション精度が向上している。

TransDeepLab と比べて、DeepTransUNet が軽量化を達成しながらも精度で優れている点特徴的である。300 エポックのトレーニング後、DeepTransUNet は Dice 係数 61.86% を達成し、TransDeepLab の 13.41% を超える性能を示した。ただし、TransUNet の 59.89% に対しては若干の改善にとどまった。

第三章 提案手法

従来手法を検討した結果、U-Net のエンコーダ・デコーダ構造に基づき、特徴抽出能力、ひいてはモデル効果を高めるために、提案手法では Transformer を用いる。そして、汎用モデルの中で最も効果が良い TransUNet をベースに、Swin Transformer と組み合わせたハイブリッドモデル設計し、以下の四つの新しいモデルを提案する。

- 提案モデル 1 : swinTUNet
- 提案モデル 2 : swinTWUNet
- 提案モデル 3 : swinTXUNet[36]
- 提案モデル 4 : swinTAUNet[36]とその改良版

それぞれの大きな改善点を述べると、提案モデル 1 では TransUNet のエンコーダ末の ViT の部分を Swin Transformer に置き換えること、提案モデル 2 ではエンコーダ部分の浅層で CNN と Swin Transformer を直列的に結合することである。そして、提案モデル 3 では各エンコーダ層で CNN と Swin Transformer を並列に適用すること、提案モデル 4 では各エンコーダ層で CNN と Swin Transformer を独立して並列に処理することである。

3.1. swinTUNet

提案モデル 1 の swinTUNet は、従来のモデルの課題を解決することを目的としており、特に Swin Transformer の有効性に焦点を当てている。提案モデル 1 は、主に CNN と Swin Transformer の組み合わせを基盤としており、エンコーダ・デコーダ構造を採用している。TransUNet (図 13) に対して、ViT の部分を Swin Transformer に変更する (図 18)。




図 18 : swinTUNet の構造

エンコーダ部分では、入力画像を段階的に特徴抽出し、浅いレベルから深いレベルまでの情報を効率的に学習する。具体的には、初期の段階で畳み込み層と GeLU (Gaussian Error Linear Unit, ガウス誤差線形ユニット) 活性化関数を用いた特徴抽出が行われ、マックスプーリングによって空間解像度を段階的に縮小していく。この過程で、空間的な情報を圧縮しながらも主要な特徴を保持することが可能となる。エンコーダの末では、Swin Transformer を利用して全体的な特徴を効果的に捉える仕組みを導入する。Swin Transformer は、画像を小さなパッチに分割し、自己注意機構を用いて各パッチ間の関係性を学習する。この設計により、入力シーケンス全体の特徴も適切にモデル化できるようになる。この部分はモデルの特徴抽出能力を高める上で重要な役割を果たしている。

エンコーダによって圧縮された情報を最大限に統合し、高次元の表現として精緻化するため、ボトルネックを三つの畳み込み層で構築する。これにより、入力画像の複雑な構造を効果的に捉えることが可能になる。また、デコーダ部分におけるアップサンプリングおよび特徴の復元を行う際に、この特徴マップが基盤となり、セグメンテーションタスクにおいて必要な、正確な境界情報や細部の再構築をサポートする。

一方、デコーダ部分では、エンコーダで抽出された特徴をもとに、入力画像と同じ解像度の出力を生成するための復元処理が行われる。具体的には、ConvTranspose 層を用いて空間解像度を徐々に復元し、アップサンプリングを行う過程で Skip-Connection を利用してエンコーダの低レベル特徴を統合する。これにより、画像の細部に至る情報を保持しながらセグメンテーション結果を生成することが可能となる。この過程で、畳み込み層や GeLU 活性化関数を再度用いて特徴を処理し、最終的な出力層でシグモイド関数を適用してセグメンテーションマップを生成する。

改善点としては、まず、Swin Transformer を採用することで、全体的な画像特徴の捕捉力が向上した点が挙げられる。さらに、デコーダでの Skip-Connection の効果的な利用により、空間的な詳細情報を損なうことなく出力画像を復元できるようになっている。また、従来の TransUNet と比較して、計算効率の改善も図られており、パラメーター数の削減を実現しつつ、性能が向上している。また、GeLU 活性化関数を利用することで、学習の収束が速くなり、より滑らかな非線形性が導入されている。

3.2. swinTWUNet

提案モデル 2 の swinTWUNet は、Swin Transformer と CNN を緊密に組み合わせた新しいアプローチを採用し、浅層でのグローバル特徴の抽出を最大限に活用することを目的としている。この方法は、医用画像セグメンテーションの分野での小さな病巣の認識精度を向上させるために設計されている。

swinTWUNet もエンコーダとデコーダの二つの主要部分で構成されているが、提案モデ

ル 1 の swinTUNet とは異なり、それぞれの層で CNN と Transformer の強みを融合している。エンコーダ部分では、入力画像がまず 3×3 のカーネルサイズを持つ畳み込み層を通過し、初期の低次元特徴を抽出する。このプロセスでは、学習の安定性と非線形性を確保するため、Group Normalization と GeLU 活性化関数が使用されている。特徴抽出後、浅層の各畳み込み層に直結して Swin Transformer モジュールが配置される。この配置により、局所的な特徴を捉える CNN と、全体的な特徴を学習する Transformer が相互に補完し合う設計となっている (図 19)。

エンコーダでは、Swin Transformer で使われている Patch Merging が適用され、空間次元を段階的に圧縮することで計算コストを削減している。そのため、プーリング層より情報の損失が減少しながらより深い層での特徴学習が効率的に行われるようになっている。また、各層の Swin Transformer モジュールは、グローバル情報を強調するデザインとなっており、特に浅層での全体的な特徴の取り込みを重視している。このようなアプローチは、既存モデルでは複雑な医療画像における小さな病巣の識別に寄与している。




図 19 : swinTWUNet の構造

デコーダ部分では、提案モデル 1 の swinTUNet と同じように、エンコーダで抽出された特徴をアップサンプリングし、元の画像解像度に復元するための ConvTranspose 層を使用する。復元プロセスには、Skip-Connection が組み込まれており、エンコーダの浅層で学習された詳細な情報を結合することで、細部まで正確なセグメンテーションを実現している。また、デコーダ内の畳み込み層は、復元された特徴マップをさらに調整し、高解像度での予測精度を向上させる役割を果たしている。

swinTWUNet の改善点として、浅層での CNN と Transformer の直列的な結合による浅いレベルの特徴の学習が可能となった。これにより、従来のモデルと比較して浅層での情報損失が軽減されている。それ以外に、Patch Merging を通じて計算コストを抑えつつ、必要な情報を維持する設計が実現されている。

提案モデル 1 の swinTUNet と比較すると、swinTWUNet は浅層での Transformer 活用の工夫により、グローバル情報を活用している点が特徴的である。swinTUNet は、主にエンコーダの末で Transformer を活用していたが、swinTWUNet では浅層から Transformer を導入することで、局所のおよび全体的な特徴がより密接に融合されている。

3.3. swinTXUNet

提案モデル 3 の swinTXUNet[36]は、Swin Transformer と CNN を緊密に組み合わせた新しい構造を目指して設計されたモデルであり、提案モデル 2 の swinTWUNet をベースにしてハイブリッドアーキテクチャを採用している。swinTXUNet は、浅層から深層まで特徴を効果的に抽出するため、各エンコーダ層で CNN と Transformer を並列に適用し、それぞれの出力を次の層へ結合する新しい方法を提案している。この設計により、局所的な幾何学的特徴と全体的な特徴情報を同時に扱うことが可能となり、従来のモデルに比べて性能が大幅に向上することが期待される。

まず、図 20 に示す swinTXUNet のアーキテクチャもエンコーダ、ボトルネック、デコーダの三つの部分に分かれる。エンコーダでは、入力画像が畳み込み層を通過し、チャンネルを調整しながら特徴マップが生成される。その後、特徴マップは「TXU モジュール」と呼ばれるモジュールを通じて処理される。このモジュールは、図 21 に示すように CNN ブランチと Transformer ブランチで構成されている。SCConv[37]に触発され、本研究のデータが五種類の脳卒中画像を 2D でフレームごとに処理されていることを考慮すると、SCConv を使用することでチャンネルごとに処理でき、CNN ブランチの特徴抽出能力を高めることができる。一方、Transformer ブランチでは、Swin Transformer モジュールが長距離依存性を捉え、グローバルな特徴を抽出する。この両ブランチの出力は結合され、次の層に渡される。

TXU モジュールは三つ積み重ねられており、段階的に特徴を深めながらエンコーダを構成している。これらの処理によって抽出された特徴は、ボトルネック層でさらに統合され、深い特徴として要約され、セグメンテーションの精度を向上させている。

デコーダ部分では、エンコーダからの特徴をアップサンプリングし、元の画像解像度に復元する作業が行われる。ここでは、提案モデル 1 や 2 と同様に、Skip-Connection を利用してエンコーダの各層からの特徴を取り入れることで、デコーダでの情報損失を最小限に抑えている。また、ConvTranspose 層がアップサンプリングを効率的に実行し、セグメンテーションマップを生成している。

swinTXUNet の改善点は、特に CNN と Transformer の統合方法にある。提案モデル 2 の swinTWUNet では、CNN による局所的な特徴の抽出と Transformer によるグローバル特徴の学習を別々の段階で行っていたが、swinTXUNet では各エンコーダ層でこれらを並列に処理することで、両者の相乗効果を最大限に活用している。また、TXU モジュールによるブランチ間の特徴統合が効果的であり、グローバルと局所の特徴が密接に関連付けられているため、swinTWUNet より、エンコーダが改善されている。swinTWUNet では CNN の出力を Transformer で処理していたため、各層での局所的な情報と全体的な情報の抽出が不十分だった。それに対して swinTXUNet は、各エンコーダ層の特徴抽出を分けたことで、浅層から深層まで情報の損失を抑え、より正確なセグメンテーションを実現している。一方で、全層での特徴統合が計算コストを増加させるという課題もある。




図 20 : swinTXUNet の構造 [36]




図 21 : TXU モジュールの構造

3.4. swinTAUNet

提案モデル 4 の swinTAUNet[36]は、提案モデル 3 の swinTXUNet の構造をさらに最適化し、より高い効率性と精度を実現するために提案されたモデルである。swinTAUNet は特徴の融合をデコーダでアップサンプリングの段階に限定する新しいアプローチを設計し、swinTXUNet で発見された計算コストの増加やモデルの複雑性の問題を軽減することを目的としている。

図 22 に示す swinTAUNet の設計も、エンコーダ、ボトルネック、デコーダの三つの主要な部分で構成されている。まず、エンコーダでは、「TAU モジュール (図 23)」と呼ばれるモジュールを通じて処理される。入力画像が複数の畳み込み層と Transformer 層を独立した二つのブランチで処理される。CNN ブランチは SCConv を用いて局所的な特徴を抽出し、画像の幾何学的特性を捉える。一方、Transformer ブランチは Swin Transformer モジュールを利用して全体的な情報を学習し、長距離依存性を効果的に捕捉する。この二つのブランチは、エンコーダ全体が最後まで独立して機能し、特徴の統合は Skip-Connection およびボトルネックで行われる。

この特徴統合の部分を変更することで、swinTXUNet での各層での統合より計算効率を大幅に向上させている。各層での統合を避けることで、モデルの計算負荷が軽減され、特

に浅層での情報処理がより効率的に行われるようになっている。Skip-Connection の段階では、エンコーダで抽出された特徴がデコーダでのアップサンプリングに直接利用される。この過程で、浅層からの情報が高次元の特徴と統合されることで、セグメンテーション精度がさらに向上している。

ボトルネック部分では、エンコーダから出力された特徴が集約され、さらに特徴を抽出する処理が行われる。

デコーダ部分では、これまでの提案モデルと同様に、ConvTranspose 層によるアップサンプリングが行われ、元の画像解像度に復元が進められる。Skip-Connection を通じてエンコーダから受け取った特徴が融合されることで、画像の細部情報が補完され、セグメンテーション精度が向上している。デコーダの畳み込み層は、チャンネル調整や復元された特徴の精度を高め、セグメンテーション結果のノイズを抑制する役割を担っている。




図 22 : swinTAUNet の構造 [36]




図 23 : TAU モジュールの構造

提案モデル 3 の swinTXUNet と比べて、提案モデル 4 の swinTAUNet は主に計算効率と性能のバランスで優れている。swinTXUNet は各エンコーダ層で特徴を統合する設計だったため、モデルの複雑性が高まり、計算コストが増加していた。それに対して、swinTAUNet では統合を必要最小限に抑えたことで、効率性を保ちながら精度の向上を実現している。また、マルチスケールアテンションによる柔軟な特徴融合は、病変検出能力を強化し、セグメンテーション精度をさらに引き上げている。

さらに、Spatial Pyramid Pooling 構造からアイデアを得て、TAU モジュールに基づくマルチスケールウィンドウアテンションの構造を取り入れ、TAU モジュールの Transformer の数を三つに固定し、ウィンドウサイズを 4×4 、 8×8 、 16×16 に設定する（図 24）。この改良された swinTAUNet は swinTAUNet_2 と表記する。これにより、異なるスケールの特徴画像をマルチスケールで融合し、より豊かな特徴情報を得て、異なるスケールの病巣を識別するモデルの能力を向上させることを試みている。




図 24 : swinTAUNet_2 の改良モジュールの構造

第四章 実験

4.1. データセット

検証用データは ISLES 2018 Challenge[32][38][39]から取得し、これは発症 8 時間以内に大血管閉塞が診断された 103 例の匿名化画像を含む。これらの患者は二つの多施設虚血性脳卒中コホート研究[40][41]から集約され、年齢、NIHSS（National Institutes of Health Stroke Scale の略であり、脳卒中の神経学的重症度を評価するスケール）、発症から CT までの時間、CT から DWI（Diffusion-Weighted Image、拡散強調画像）までの時間、及び 103 症例全体での CT スキャナ製造元などの臨床情報は既報である。しかし、ISLES 2018 データセットそのものには付与されていなかった[39]。CTP は入院時に取得され、DWI は CTP 実施後 3 時間以内に撮像され、コンピューター断層撮影（CT）、局所脳血液量（CBV）、局所脳血流量（CBF）、time to peak of the residue function（T-max）、局所平均通過時間（MTT）と DWI の六つの医療測定装置（モダリティ）の画像及び正解ラベル画像（Ground Truth）で構成される。図 25 に画像例を示す。なお、同図において正解ラベル画像は右端の Mask である。

103 例のうち 63 例のサブセットにおいては、CTP による虚血コア描出の参照として使用する DWI 病変セグメンテーションが提供されていた。本研究では、この DWI 病変ボリュームを参照とできる 63 例のみを対象とした。なお、本研究で対象とした 63 例のサブセットに対応する分割された臨床データは入手できなかった。データセットは、GE Healthcare、Philips Healthcare、Siemens Healthineers、Toshiba Medical といった様々なメーカーのスキャナ、2～16 cm 範囲の軸方向カバレージ、43～64 秒間のスキャン時間を有する多様な条件で取得された。これらすべての CTP 研究は動態補正され、1 秒ごとのスキャン間隔へ再サンプリングされた[39]。また、ISLES データセットには軸方向カバレージが短いスキャナで必要となる二重スラブ（“A/B”表記）の CTP 研究が含まれており、これらは処理上で個別研究として扱われるが、統計解析上は一人の患者として扱われた。ISLES 2018 データセットにおける画像取得に関するすべての手続きおよび実験プロトコルは、参加各施設の倫理審査委員会で承認されている。




図 25：虚血性脳卒中 CT/CTP データセット ISLES2018[32]における各モダリティの撮影画像と専門家による正解ラベル Mask の例（図 1 の再掲）

4.2. 前処理

本研究で用いる ISLES 2018 データセットには、モデルの評価に用いるコンペティション用のテストデータセットに適切な正解ラベルがついていないため、テストデータからでは評価指標を算出することができない。したがって、63 人の患者からの 94 ケースのトレーニングデータのみが利用可能であり、分析対象は各患者の 3 次元 CT/CTP スキャン画像となる。これらの画像は CT、CBV、CBF、T-max、MTT といった異なるモダリティを含み、それぞれ 256×256 の軸方向解像度を有する。また、スライス数は患者ごとに異なり、2 スライスから最大 18 スライスまで変動する。

データ読み取り手順としては、まず生データである nii 形式の 3D 配列データを Tensor の形式へと変換する。変換時には float 型として投影し、 $(1, 256, 256)$ の形状を持つ行列としてマッピングする。これを CT、CBV、CBF、T-max、MTT のそれぞれについて実行し、最終的に $(5, 256, 256)$ の Tensor データを 1 スライスあたり構成することが可能となる。すなわち、単一の患者データからは、スライス数に対応する複数の $(5, 256, 256)$ の Tensor データが生成されることになる。例えば、ある患者が 10 スライスを有する場合、10 個の $(5, 256, 256)$ の Tensor データが得られ、別の患者が 3 スライスを有する場合には 3 個の同様の Tensor データが得られる。これらの Tensor データは、そのまま深層学習モデルへの入力として用いることができる。具体的には、スライスごとに CT、CBV、CBF、T-max、MTT といった異種のモダリティを重ね合わせたデータを 1 セットとしてモデルへ逐次投入し、ネットワークパラメータを更新する。こうしたスライス毎の Tensor データ入力は、患者間でのデータ数の不均一性や、各モダリティにわたる情報の統合を柔軟に扱うために有効である。

63 人の患者から集められたトレーニングデータセットは、各患者について 2~18 枚の 3D スライスを含む複数モダリティの CT データから構成され、500 枚の 2D スライスに変換された。そのうち 420 枚をトレーニングデータ、80 枚をテストデータとして、それぞれの深層学習モデルをトレーニングした。これらのデータを利用することで、モデルは深度画像情報および複数モダリティ間の特徴を学習することが可能となり、各患者の状態を網羅的に捉えつつ、有効な予測モデルの構築を試みることができる。

4.3. 損失関数と評価指標

4.3.1. Dice 係数

Dice 係数 (Dice coefficient、ダイス係数) [42]は、集合の類似度を測定するための指標の一つである。この指標は、二つの集合 A と B の間の重なりを定量化し、以下のように計算される：

$$\text{Dice} = \frac{2|A \cap B|}{|A| + |B|} \quad (6)$$

ここで、 $|A|$ は集合 A の要素数（あるいはセグメントされたピクセル数）、 $|B|$ は集合 B の要素数を意味する。Dice 係数の値は 0 から 1 の範囲を取り、1 は完全一致、0 は一致しないことを示す。

医学分野では、特に画像診断や治療計画におけるセグメンテーションタスクで、この指標が用いられることが一般的になっている。たとえば、MRI や CT スキャン画像における臓器や腫瘍の分割精度を評価する際に、予測された領域と真の領域との一致度を示すために Dice 係数が用いられる。この評価方法は直感的かつ計算コストが低いという利点があり、研究者や臨床現場において重要な基準として認識されている。近年の研究では、深層学習を用いたセグメンテーション手法が急速に進歩しており、Dice 係数は依然としてその性能を評価する際の主要な指標である。

4.3.2. Soft Dice Loss

Soft Dice Loss (ソフトダイス損失) [43]は、セグメンテーションタスクで広く用いられる損失関数で、主に医用画像処理やコンピュータビジョンにおいて効果的とされている。この損失関数は、従来の Sorensen-Dice 係数に基づいており、シグモイド関数を使い、多くの実験的研究で良好な性能を示している。二値化されたピクセル単位的一致率を評価する指標から派生したものであるが、連続値で表現された予測マップと正解マップ (Ground Truth) を直接扱うために設計されている。

Dice 係数は、主に集合間の類似度を評価する指標であり、この定義は二値化されたデータに対して使用されるが、Soft Dice Loss 関数では、集合ではなく連続値のテンソルを考慮する。この場合、テンソル要素間の積と和を用いて以下のように拡張される：

$$SoftDice = \frac{2 \sum_i p_i t_i}{\sum_i p_i^2 + \sum_i t_i^2} \quad (7)$$

ここで p_i は予測マップの値、 t_i は正解マップの値である。この式では、予測と正解が完全に一致した場合に値が 1 となり、完全に一致しない場合に 0 に近づく。損失関数として利用するためには、Soft Dice 係数を最大化するのではなく最小化する必要がある。これにより、Soft Dice Loss 関数は以下の形で表現される：

$$Loss = 1 - SoftDice \quad (8)$$

Soft Dice Loss 関数の利点の一つは、不均衡なデータセットに対する堅牢性である。特に、セグメンテーションタスクでは対象物の領域が画像全体に対して非常に小さい場合が多く、従来の交差エントロピー損失では正例に対するペナルティが過小評価されることがある。Soft Dice Loss では、Dice 係数に基づく正規化が施されるため、このような問題が軽減される。医療分野のセグメンテーションにおいて、交差エントロピー損失と並んで最も人気のある損失関数となり、nnU-Net[44]のような有名なフレームワークでも使用されている。

4.4. 実験

4.4.1. 実験環境

本研究では、提案手法の有効性を確認するため、ISLES2018 データセットを用いて検証実験を行い、すべての深層学習モデルは同じランダムシードを用いて学習された。そして、24GB のグラフィックメモリを搭載した RTX3090 と pytorch2.1.0 フレームワークを用いて、300 ラウンドの学習を行った。提案手法の Optimizer は AdamW とし、初期学習率は 5.23e-05 とし、ReduceLROnPlateau の min 戦略を用いて更新し、Dice 係数に基づく Soft Dice Loss 関数を用いてモデル学習を実行した。

提案手法としては、第三章で説明した swinTUNet、swinTWUNet、swinTXUNet、swinTAUNet、swinTAUNet_2 の五つであり、従来手法の DeepLabV3、DeepTransUnet（先行モデル）、FCN8s、TransUnet、UNet の五種類と比較した。

4.4.2. 実験結果

420 枚のトレーニングデータに対するすべての深層学習モデルのトレーニング結果を図 26 に示す。縦軸は Dice 係数を表し、モデルのセグメンテーション精度を評価する指標で

ある。横軸はエポック（Epoch）で、トレーニングデータ全体を何回繰り返して学習させるかを表す学習回数である。ほとんどモデルが学習を繰り返すことによって、Dice 係数を向上させていることが分かる。




図 26：すべての深層学習モデルのトレーニング結果

分析しやすくするために、この結果を従来手法と提案手法の二つ図に分ける。図 27 は、五つの従来モデルのトレーニング結果を示している。

DeepLabV3（グラフの青線）の結果を見ると、トレーニング開始時点から安定しており、最初の数回は順調に進んでいたが、何らかの理由で学習を継続することができなかった。

先行モデルの DeepTransUNet（オレンジ線）の結果は、エポック数が増加するにつれて大きな振動を示しており、特定のエポックで急激に性能が向上するが、その後再び性能が大きく低下する局面も見られる。トレーニング結果が不安定であるが、場合によっては高い Dice 係数を達成していることから、特定の条件下では優れた性能を発揮する可能性がある。

FCN8s（緑線）は、最初のエポックで急激に性能が向上するが、比較的早い段階で収束し、ほぼ一定の Dice 係数を維持している。ただし、全体として他のモデルより精度が低く、FCN8s の性能が限定的であることが示唆される。

TransUNet（赤線）は、トレーニング初期から Dice 係数が急激に上昇し、その後は緩やかに改善しつつ、比較的高い値で安定している。このような事前学習ありモデルは収束が早く、全体的に良好な性能を示しており、Dice 係数の変動も少ないため、安定性と精度の

バランスが取れている。

UNet（紫線）は、トレーニング初期段階で急激に性能が向上し、その後は一貫して高い Dice 係数を維持している。パフォーマンスは全体的に安定しており、高い精度を達成していることから、セグメンテーションタスクにおいて結構堅実な選択肢である。

全体として、FCN、UNet、TransUNet は、収束速度が速く、学習結果が安定しており、良好な精度を維持している。DeepTransUNet は、学習プロセスが少しでこぼこしているものの、最終的に約 60%の学習精度を維持している。




図 27：従来モデルのトレーニング結果

次に提案モデルのトレーニング結果を図 28 に示す。五つの提案モデル swinTUNet、swinTWUNet、swinTXUNet、swinTAUNet、swinTAUNet_2 の結果を示している。

swinTUNet（緑線）は、最初のエポックから緩やかに性能が向上し、200 エポック付近で収束している。最終的な Dice 係数は他のモデルに比べて低く、従来モデル TransUNet より少しの改善が見られるが、性能は限定的であると考えられる。

swinTWUNet（赤線）は、トレーニング初期の Dice 係数が他のモデルと比べて高く、50 エポック付近で急激な性能向上が見られる。その後も Dice 係数の変動が大きい、最終的な性能は安定している。swinTWUNet の収束は他の手法より早い、精度の改善があまり見られない。

swinTXUNet（紫線）は、トレーニング初期から緩やかに性能が向上し、100 エポック付近である程度安定するが、最終的な Dice 係数は swinTWUNet より良い。swinTXUNet は全体的に安定性が高いだけでなく、新しい特徴抽出方法の有効性も示している。

swinTAUNet（青線）は、最初のエポックから緩やかに Dice 係数が上昇し、100 エポック以降では安定して高い性能を示している。このモデルのトレーニング曲線は全体的に滑らかであり、学習の安定性が高いことを示している。最終的な Dice 係数も swinTXUNet より高く、良好なセグメンテーション性能を持つことが分かる。

swinTAUNet_2（オレンジ線）は、swinTAUNet と類似した挙動を示しているが、改善によりトレーニング初期の性能向上が swinTAUNet よりもやや急激である。さらに、250 エポック以降ではわずかに swinTAUNet を上回る Dice 係数を示しており、全体的に最も高い精度を達成している。




図 28：提案モデルのトレーニング結果

従来手法と比較すると、提案手法では全体的に Dice 係数が高いことが特徴である。特に swinTXUNet のセグメンテーション精度は従来手法に比べて約 9%向上し、swinTAUNet のセグメンテーション精度は従来手法に比べて約 11%向上し、改良された TAU モジュールを用いた swinTAUNet_2 のセグメンテーション精度は従来手法に比べて約 16%向上した。一方で、事前学習に依存しないため、提案手法は従来方法よりも収束が遅いことがわかる。

総じて、提案手法では swinTAUNet および swinTAUNet_2 が高い性能と安定性を示し、特に swinTAUNet_2 は全モデル中で最も高い精度を達成している。訓練の後期においてモデルはスムーズに収束し、精度が低下していないことから、学習が順調に行われていることがわかる。従来手法の結果と合わせて考えると、提案手法は全体的に性能が向上しており、セグメンテーションタスクにおいて非常に有望であることが示唆される。

図 29 は、80 枚のテストデータに対してすべての深層学習モデルのテスト結果を平均 Dice 係数で比較したものである。縦軸は平均 Dice 係数を表し、各モデルのセグメンテーション性能を評価している。このグラフから分かるように、提案モデルの swinTAUNet_2 が最も高い平均 Dice 係数を達成し、0.78948 という結果を示している。次いで提案モデルの swinTAUNet が 0.73308 であり、この二つのモデルが他のモデルと比較して優れた性能を持つことが分かる。これらの結果は、トレーニング過程で swinTAUNet_2 および swinTAUNet が高い精度を示していたことと一致している。

一方で、swinTXUNet の平均 Dice 係数は 0.68327 であり、swinTAUNet_2 および swinTAUNet に劣るものの、一定の性能を示している。しかし、トレーニング過程での若干の課題が見られたことを考えると、性能向上の余地があると考えられる。swinTWUNet は平均 Dice 係数が 0.59078 であり、トレーニング中の性能の劣勢を反映して他のモデルに比べて低い精度を示している。

一方で、従来モデルの DeepTransUNet、TransUNet、U-Net、FCN8s の結果も含まれているが、いずれも提案手法モデルに及ばない。DeepTransUNet の平均 Dice 係数は 0.62257、TransUNet は 0.6228、UNet は 0.63559、FCN8s は 0.58754 である。

これらの結果を総合すると、swinTAUNet_2 および swinTAUNet が最も優れたモデルであり、特に swinTAUNet_2 はトレーニングとテストの両方で最も高い性能を示していることが明らかである。また、従来のモデルと比較して提案手法モデルが全体的に優れていることから、提案手法の有効性を証明しているといえる。




図 29 : すべての深層学習モデルのテスト結果

最後に、実際の深層学習モデルの出力画像の例を図 30 に示す。左から順に、CT 画像と脳血液量 (CBV)、脳血流 (CBF)、ピークまでの時間 (Tmax)、平均通過時間 (MTT) を含む四種類の CTP 画像、および評価に使用した正解ラベル画像 (ground truth) の名前付きマスクである。その次に、改良型提案モデルの swinTAUNet と四つ従来モデルの出力画像である。結果から見ると、一行目、二行目、三行目のような小さい病巣では、提案手法が良好なセグメンテーションを維持している。四行目や五行目のような大きい病巣に対して、従来手法より提案手法が形も大きさも正確に検出できていることが分かる。全体として、提案手法はセグメンテーションのサイズと形状を大幅に改善し、より極端なケースでもセグメンテーション性能を維持できることが示された。




図 30 : 深層学習モデルの出力画像の例

4.4.3. アブレーション実験

swinTAUNet における三つ Skip-Connection の効果を検証するため、改良前の swinTAUNet についてアブレーション実験を行った。アブレーションとは、深層学習モデルにおいて構成要素の一部を取り除いて実験を行い、結果を比較することである。Optimizer、トレーニングエポックの数、トレーニング環境などのパラメーターは前の実験と同じになる。

まず、深層学習モデルを図 31 のように抽象化にする。次に、各アブレーション実験の名称を図 32 の形式で定義する。




図 31：抽象化したモデルの構造

skip0	すべてのskip-connectionを維持する
skip1	skip-connection1のみを削除する
skip2	skip-connection2のみを削除する
skip3	skip-connection3のみを削除する
skip4	skip-connection1のみを維持する
skip5	skip-connection2のみを維持する
skip6	skip-connection3のみを維持する
skip7	すべてのskip-connectionを削除する

図 32：アブレーション実験名称の定義

テストデータに対する実験結果を図 33 に示す。縦軸は平均 Dice 係数である。

まず、全ての Skip-Connection を維持した skip0 の Dice 係数が最も高く、0.733 となっている。これは Skip-Connection が情報の効果的な伝達を可能にし、モデルの性能を最大化していることを示している。swinTAUNet の Skip-Connection は、DeepTransUNet よりも役に立ち、不可欠であることが見られる。

次に、Skip-Connection を部分的に削除した場合について、skip1 ではスコアが 0.6887、skip2 では 0.69008 となっており、これらは Skip-Connection を一つ削除しただけの場合の性能低下が比較的緩やかであることを示している。skip3 の場合、スコアは 0.67452 であり、他の Skip-Connection に比べて、削除する影響が若干大きいことが見られる。

一方で、Skip-Connection を一つだけ維持した場合、性能は大幅に低下する傾向が見られる。skip4 のスコアは 0.61668、skip5 は 0.61389、skip6 は 0.5692 となっており、いずれの場合も Skip-Connection が複数存在する場合に比べて性能が劣る。

最後に、全ての Skip-Connection を削除した skip7 のスコアは 0.48857 と最低であり、Skip-Connection が全くない場合、情報伝達が制限され、モデル性能が大幅に低下することが分かる。

これらの結果から、全ての Skip-Connection を維持することがモデル性能を最大化する上で重要であり、Skip-Connection の削除や部分的な維持がモデルのセグメンテーション性能に直接的な影響を及ぼすことが分かる。また、Skip-Connection の削除がどの程度性能に影響を与えるかは、削除される Skip-Connection の位置や役割に依存することも明らかである。




図 33 : アブレーション実験の結果

第五章 考察

セマンティックセグメンテーションは多くの応用分野で重要な課題であるが、現実の複雑な状況において高性能を達成することは依然として非常に困難である。特に医用画像セグメンテーションの分野では、コントラストの低さ、ノイズの干渉、病変の形状や大きさの多様性、さらには撮影装置の違いによるデータのばらつきなど、さまざまな問題が存在しており、大きな課題に直面している。技術の発展に伴い、コンピュータービジョンの分野ではより効果的な新技术が多く登場している。しかし、脳卒中画像セグメンテーションにおいてこれらの技術を直接適用する場合、効果は限定的である。そのため、既存技術を基に脳卒中病変の特徴に特化した改良が必要とされている。

本研究では、従来の研究成果を十分に参考にし、U-Net を基盤として、特徴抽出における Transformer の利点を組み合わせ、モデルのエンコーダ部分を大幅に改良した新たな四種類のモデルを提案した。その中で、SwinTUNet は従来の ViT に対する Swin-Transformer の有効性を検証し、SwinTWUNet は浅層 Transformer による特徴抽出効果を探求した。さらに、SwinTXUNet は SwinTWUNet を基に最適化を行い、並列構造を通じて特徴マップの利用効率をさらに向上させた。また、SwinTAUNet はモデル設計をさらに改良し、精度と計算時間の両面で新たな突破口を見出した。そして、Transformer モジュールの改良を通じて最終的に 76%のトレーニング精度を達成し、従来モデルと比較して約 15%のセグメンテーション精度の向上を実現した。また、テスト結果およびモデルの実際の画像出力結果は提案手法の有効性を裏付け、特徴抽出における CNN と Transformer のハイブリッドモデルの可能性を示した。さらに、アブレーション実験では、モデルにおける Skip-Connection 構造の存在の必要性を検証した。

しかし、本研究には依然としていくつか未解決の問題が存在している。まず、データセットが異なる高さの 3D CT 画像で構成されているため、3D 畳み込みを直接使用して特徴を抽出することができず、2D データに変換した際に深度方向のデータ特徴が失われている。このため、エンコーダを最適化し、3D データを直接読み込む方法や、2D+RNN を使用してデータを読み込む方法を採用すれば、モデルの性能をさらに向上させる可能性がある。次に、本研究で使用したデータは CT 画像と四種類の CTP 画像であるが、実際の脳卒中診断において CT 画像は主に脳出血の検出に使用され、虚血性脳卒中の検出には適していない。さらに、CT 画像は出血に対しては敏感である一方、虚血領域の表現には限界があり、モデルの性能に影響を及ぼしている可能性がある。本研究では四種類の CTP 画像を個別に読み込み、同一のモデルで特徴を抽出しているが、各 CTP 画像データを個別に処理するモデルを設計し、最終的に四つの分岐結果を統合することで、より良い結果を得られる可能性がある。それに加えて、病変を分割することで得られるセグメンテーション結果から Radiomics 特徴量を抽出し、Radiomics 特徴量を臨床データと組み合わせ、投票などの方法で出力結果を統合することによっても、モデルのセグメンテーション性能が向上する可能

性がある。また、病変の分類と分割を多タスク学習として組み合わせることで、モデル性能を向上させると同時に、モデルの汎用性を高めることができる可能性がある。最後に、データ処理において反転、ミラーリング、スケーリングなどのデータ拡張手法や生成モデルを用いたデータ拡張手法を適用することで、モデル性能の向上に寄与する可能性が考えられる。

謝辞

本研究を進めるにあたり、研究室の皆様にご指導ご鞭撻を賜りました。指導教員の名古屋市立大学大学院理学研究科の渡邊裕司教授には大変お世話になりました。また、博士後期課程の小林敏樹さんから貴重な意見を頂きました。そして、本研究に協力して頂いた方々に感謝を申し上げます。

参考文献

- [1] 木村和美, "病態," 日本内科学会雑誌, vol. 98, no. 6, pp. 1224–1230, 2009, doi: 10.2169/naika.98.1224.
- [2] World Health Organization (WHO) et al. "Cause-specific mortality, 2000-2019," 2020. [Online]. Available: <https://www.who.int/data/global-health-estimates>. [Accessed: Nov. 19, 2024].
- [3] L. Pu, L. Wang, R. Zhang, T. Zhao, Y. Jiang, and L. Han, "Projected Global Trends in Ischemic Stroke Incidence, Deaths and Disability-Adjusted Life Years From 2020 to 2030," *Stroke*, vol. 54, no. 5, pp. 1330–1339, 2023, doi: 10.1161/STROKEAHA.122.040073.
- [4] 厚生労働省, "令和 3 年 (2021) 人口動態統計 (確定数) の概況," Sep. 16, 2022. [Online]. Available: <https://www.mhlw.go.jp/toukei/saikin/hw/jinkou/kakutei21/>. [Accessed: Nov. 19, 2024].
- [5] 三重県健康福祉部, "三重県循環器病対策推進計画," Mar. 2022. [Online]. Available: <https://www.mhlw.go.jp/content/10900000/001117012.pdf>. [Accessed: Nov. 19, 2024].
- [6] 田中耕太郎, "脳梗塞急性期の病態と治療のターゲット," *臨床神経学*, vol. 53, no. 11, pp. 1159–1162, 2013, doi: 10.5692/clinicalneurol.53.1159.
- [7] "虚血性脳卒中 - 07. 神経疾患 - MSD マニュアル プロフェッショナル版," July 2023. [Online]. Available at: <https://www.msdmanuals.com/ja-jp/professional/07-%E7%A5%9E%E7%B5%8C%E7%96%BE%E6%82%A3/%E8%84%B3%E5%8D%92%E4%B8%AD/%E8%99%9A%E8%A1%80%E6%80%A7%E8%84%B3%E5%8D%92%E4%B8%AD> [Accessed: Nov. 19, 2024].
- [8] T. Hirano, "CT・MRI 診断," 日本内科学会雑誌, vol. 98, no. 6, pp. 1231–1239, 2009, doi: 10.2169/naika.98.1231.
- [9] 出口一郎, 武田 英孝, 古屋 大典, 服部 公彦, 名古屋 春満, 加藤 裕司, 福岡 卓也, 棚橋 紀夫, "脳梗塞超急性期症例の t-PA 静注療法適応選択における CT perfusion の有用性について," *脳卒中*, vol. 31, no. 2, pp. 86–95, 2009, doi: 10.3995/jstroke.31.86.
- [10] 井上 学, "急性期 CT/MRI 造影灌流画像による再灌流療法の適応," *脳卒中*, vol. 41, no. 1, pp. 52–57, 2019, doi: 10.3995/jstroke.10621.
- [11] K. Nishimura, K. Ogasawara, T. Kitazono, and K. Iihara, "Impact of Physician Volume and Specialty on In-Hospital Mortality of Ischemic and Hemorrhagic Stroke," *Circulation Journal*, vol. 85, no. 10, pp. 1876–1884, 2021, doi: 10.1253/circj.CJ-20-1214.
- [12] Y. Hayashi, T. Shimada, N. Hattori, T. Shimazui, Y. Yoshida, R. E. Miura, Y. Yamao, R. Abe, E. Kobayashi, Y. Iwadate, T. Nakada, "A prehospital diagnostic algorithm for strokes using machine learning: a prospective observational study," *scientific reports*, no. 11, p. 20519, 2021. doi: 10.1038/s41598-021-99828-2.
- [13] Y. LeCun, L. Bottou, Y. Bengio, and P. Haffner, "Gradient-based learning applied to document

- recognition," *Proceedings of the IEEE*, vol. 86, no. 11, pp. 2278–2324, 1998, doi: 10.1109/5.726791.
- [14] A. Krizhevsky, I. Sutskever, and G. E. Hinton, "ImageNet classification with deep convolutional neural networks," in *Proceedings of the 25th International Conference on Neural Information Processing Systems (NIPS)*, pp. 1097–1105, 2012.
- [15] K. Simonyan, A. Zisserman, "Very Deep Convolutional Networks for Large-Scale Image Recognition," *3rd International Conference on Learning Representations (ICLR)*, pp. 1–14, 2015. arXiv: arXiv:1409.1556. doi: 10.48550/arXiv.1409.1556.
- [16] J. Long, E. Shelhamer, and T. Darrell, "Fully convolutional networks for semantic segmentation," in *Proc. IEEE Conf. Computer Vision and Pattern Recognition (CVPR)*, pp. 3431–3440, 2015.
- [17] O. Ronneberger, P. Fischer, and T. Brox, "U-Net: Convolutional networks for biomedical image segmentation," in *Proc. Int. Conf. Medical Image Computing and Computer-Assisted Intervention (MICCAI)*, pp. 234–241, 2015.
- [18] Z. Zhou, M. M. Rahman Siddiquee, N. Tajbakhsh, and J. Liang, "UNet++: A nested U-Net architecture for medical image segmentation," in *Deep Learning in Medical Image Analysis and Multimodal Learning for Clinical Decision Support, Lecture Notes in Computer Science*, vol. 11045, pp. 3–11, 2018. doi: 10.1007/978-3-030-00889-5_1.
- [19] H. Huang, L. Lin, R. Tong, H. Hu, Q. Zhang, Y. Iwamoto, X. Han, Y.-W. Chen, J. Wu, "UNet 3+: A Full-Scale Connected UNet for Medical Image Segmentation," *IEEE International Conference on Acoustics, Speech and Signal Processing (ICASSP)*, pp. 1055–1059, 2020. doi: 10.1109/ICASSP40776.2020.9053405.
- [20] X. Qin, Z. Zhang, C. Huang, M. Dehghan, O. R. Zaiane, M. Jagersand, "U²-Net: Going Deeper with Nested U-Structure for Salient Object Detection," *Pattern Recognition*, vol. 106, p. 107404, 2020, doi: 10.1016/j.patcog.2020.107404.
- [21] L.-C. Chen, G. Papandreou, I. Kokkinos, K. Murphy, A. L. Yuille, "Semantic Image Segmentation with Deep Convolutional Nets and Fully Connected CRFs," June 7, 2016, arXiv: arXiv:1412.7062. doi: 10.48550/arXiv.1412.7062.
- [22] L.-C. Chen, G. Papandreou, I. Kokkinos, K. Murphy, A. L. Yuille, "DeepLab: Semantic Image Segmentation with Deep Convolutional Nets, Atrous Convolution, and Fully Connected CRFs," *IEEE Transactions on Pattern Analysis and Machine Intelligence*, vol. 40, no. 4, pp. 834–848, 2018. doi: 10.1109/TPAMI.2017.2699184.
- [23] L.-C. Chen, G. Papandreou, F. Schroff, H. Adam, "Rethinking Atrous Convolution for Semantic Image Segmentation," Dec. 5, 2017, arXiv: arXiv:1706.05587. doi: 10.48550/arXiv.1706.05587.
- [24] L.-C. Chen, Y. Zhu, G. Papandreou, F. Schroff, H. Adam, "Encoder-Decoder with Atrous

- Separable Convolution for Semantic Image Segmentation," *Computer Vision – ECCV 2018*, In: V. Ferrari, M. Hebert, C. Sminchisescu, Y. Weiss (eds), *Lecture Notes in Computer Science*, vol. 11211, Springer, pp. 833–851, 2018. doi: 10.1007/978-3-030-01234-2_49.
- [25] A. Vaswani, N. Shazeer, N. Parmar, J. Uszkoreit, L. Jones, A. N. Gomez, L. Kaiser, I. Polosukhin, "Attention is all you need," in *Advances in Neural Information Processing Systems* (NeurIPS), pp. 5998–6008, 2017.
- [26] A. Dosovitskiy, L. Beyer, A. Kolesnikov, D. Weissenborn, X. Zhai, T. Unterthiner, M. Dehghani, M. Minderer, G. Heigold, S. Gelly, J. Uszkoreit, N. Houlsby, "An Image is Worth 16x16 Words: Transformers for Image Recognition at Scale," *International Conference on Learning Representations (ICLR)*, 2021, Jun 3, 2021, arXiv: arXiv:2010.11929. doi: 10.48550/arXiv.2010.11929.
- [27] J. Chen, Y. Lu, Q. Yu, X. Luo, E. Adeli, Y. Wang, L. Lu, A. L. Yuille, Y. Zhou, "TransUNet: Transformers Make Strong Encoders for Medical Image Segmentation," Feb. 8, 2021, arXiv: arXiv:2102.04306. doi: 10.48550/arXiv.2102.04306.
- [28] Z. Liu, Y. Lin, Y. Cao, H. Hu, Y. Wei, Z. Zhang, S. Lin, B. Guo, "Swin Transformer: Hierarchical Vision Transformer using Shifted Windows," *2021 IEEE/CVF International Conference on Computer Vision (ICCV)*, pp. 9992–10002, 2021. doi: 10.1109/ICCV48922.2021.00986.
- [29] H. Cao, Y. Wang, J. Chen, D. Jiang, X. Zhang, Q. Tian, M. Wang, "Swin-Unet: Unet-Like Pure Transformer for Medical Image Segmentation," *Computer Vision – ECCV 2022 Workshops*, In: L. Karlinsky, T. Michaeli, K. Nishino (eds), *Lecture Notes in Computer Science*, vol. 13803, Springer, 2023, pp. 205–218. doi: 10.1007/978-3-031-25066-8_9.
- [30] 馬 勁宏, 渡邊 裕司, "深層学習を用いて脳卒中画像をセグメンテーションするモデルに関する一考察," *電子情報通信学会総合大会*, p. D-16-06, 2024.
- [31] R. Azad, M. Heidari, M. Shariatnia, E. K. Aghdam, S. Karimijafarbigloo, E. Adeli, D. Merhof, "TransDeepLab: Convolution-Free Transformer-Based DeepLab v3+ for Medical Image Segmentation," *Predictive Intelligence in Medicine*, In: I. Rekik, E. Adeli, S. H. Park, C. Cintas (eds), *Lecture Notes in Computer Science*, vol. 13564, Springer, pp. 91–102, 2022. doi: 10.1007/978-3-031-16919-9_9.
- [32] "ISLES: Ischemic Stroke Lesion Segmentation Challenge 2018," <https://www.isles-challenge.org> [Accessed: May 27, 2024].
- [33] A Anitha, P Padmapriya, P Preethi, T Swetha, K Banumathi, "Fundus Image Classification of Eye Disease Using CNN Method (Convolution Neural Network)," *International Research Journal of Engineering and Technology (IRJET)*, vol. 8, issue 4, pp. 314–318, 2021.
- [34] L. Deng, "The MNIST Database of Handwritten Digit Images for Machine Learning Research [Best of the Web]," *IEEE Signal Processing Magazine*, vol. 29, no. 6, pp. 141–142, 2012, doi:

10.1109/MSP.2012.2211477.

- [35] "ImageNet Large Scale Visual Recognition Challenge 2012 (ILSVRC2012), " <https://www.image-net.org/challenges/LSVRC/2012/>. [Accessed: Nov. 19, 2024].
- [36] Y. Ba and Y. Watanabe, "Proposed Models for Improving Lesion Segmentation in Ischemic Stroke CT Images Based on Hybrid CNN-Transformer Architectures," IEEE 13th Global Conference on Consumer Electronics (GCCE), pp. 975–976, 2024. doi: 10.1109/GCCE62371.2024.10760897.
- [37] J. Li, Y. Wen, L. He, "SCConv: Spatial and Channel Reconstruction Convolution for Feature Redundancy," 2023 IEEE/CVF Conference on Computer Vision and Pattern Recognition (CVPR), pp. 6153–6162, 2023. doi: 10.1109/CVPR52729.2023.00596.
- [38] C. W Cereda, S. Christensen, B. CV Campbell, N. K. Mishra, M. Mlynash, C. Levi, M. Straka, M. Wintermark, R. Bammer, G. W Albers, M. W Parsons, M. G Lansberg, "A benchmarking tool to evaluate computer tomography perfusion infarct core predictions against a DWI standard," Journal of Cerebral Blood Flow & Metabolism, vol. 36, no. 10, pp. 1780–1789, 2016. doi: 10.1177/0271678X15610586.
- [39] A. Hakim, S. Christensen, S. Winzeck, M. G. Lansberg, M. W. Parsons, C. Lucas, D. Robben, R. Wiest, M. Reyes, G. Zaharchuk. "Predicting Infarct Core From Computed Tomography Perfusion in Acute Ischemia With Machine Learning: Lessons From the ISLES Challenge," Stroke, pp. 2328–2337, 2021. doi: 10.1161/STROKEAHA.120.030696.
- [40] M. G. Lansberg, M. Straka, S. Kemp, M. Mlynash, L. R Wechsler, T. G Jovin, M. J Wilder, H. L Lutsep, T. J Czartoski, R. A Bernstein, C. W J Chang, S. Warach, F. Fazekas, M. Inoue, A. Tipirneni, S. A Hamilton, G. Zaharchuk, M. P Marks, R. Bammer, G. W Albers, "MRI profile and response to endovascular reperfusion after stroke (DEFUSE 2): A prospective cohort study," Lancet Neurol. vol. 11, no. 10, pp.860–867, 2012. doi: 10.1016/S1474-4422(12)70203-X.
- [41] L. Lin, A. Bivard, C. R. Levi, M. W. Parsons, "Comparison of computed tomographic and magnetic resonance perfusion measurements in acute ischemic stroke: Back-to-back quantitative analysis," Stroke, vol. 45, no. 6, pp. 1727–1732, 2014. doi: 10.1161/STROKEAHA.114.0054.
- [42] L. R. Dice, "Measures of the Amount of Ecologic Association between Species," Ecology, vol. 26, no. 3, pp. 297-302, 1945. doi: 10.2307/1932409.
- [43] C. Gros, A. Lemay, J. Cohen-Adad, "SoftSeg: Advantages of soft versus binary training for image segmentation," Medical Image Analysis, vol. 71, p. 102038, 2021, doi: 10.1016/j.media.2021.102038.
- [44] F. Isensee, P. F. Jaeger, S. A. A. Kohl, J. Petersen, K. H. Maier-Hein, "nnU-Net: a self-configuring method for deep learning-based biomedical image segmentation," Nature Methods,

- vol. 18, no. 2, pp. 203–211, 2021, doi: 10.1038/s41592-020-01008-z.
- [45] M. Kistler, S. Bonaretti, M. Pfahrer, R. Niklaus, P. Büchler, "The virtual skeleton database: an open access repository for biomedical research and collaboration," *J Med Internet Res.*, vol. 15, no. 11, e245, 2013, doi: <http://doi.org/10.2196/jmir.2930>.
- [46] K. J. Chung, D. De Sarno, T.-Y. Lee, "CT perfusion stroke lesion threshold calibration between deconvolution algorithms," *Scientific Reports*, vol. 13, no. 1, p. 21458, 2023, doi: 10.1038/s41598-023-48700-6.
- [47] R. G. Nogueira et al. "Thrombectomy 6–24 h after stroke with a mismatch between deficit and infarct," *N. Engl. J. Med.* vol.378, no. 1, pp. 11–21, 2018. doi: 10.1056/NEJMoal706442.